

# Definições

Patrícia de Siqueira Ramos

UNIFAL-MG, *campus* Varginha

18 de Setembro de 2018

## 2 Definições

## a) Vetor aleatório

- $\mathbf{X}$  é um vetor com  $p$  componentes, em que cada componente é uma variável aleatória (v.a.)
- $X_i$  é uma v.a.  $\forall i = 1, 2, \dots, p$
- Cada variável pode ser analisada separadamente (pelo comportamento da sua distribuição de probabilidade), mas é melhor analisar o vetor como um todo (pode ser que haja relacionamentos entre as  $p$  variáveis)

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = [X_1 \quad X_2 \quad \dots \quad X_p]^T.$$

## a) Vetor aleatório

Ex.: Empresa de minério de ferro. Variáveis:  $X_1$ : teor de ferro,  $X_2$ : teor de umidade,  $X_3$ : granulometria.

## a) Vetor aleatório

Ex.: Empresa de minério de ferro. Variáveis:  $X_1$ : teor de ferro,  $X_2$ : teor de umidade,  $X_3$ : granulometria.

$\mathbf{X} = [X_1 \ X_2 \ X_3]^T$  é um vetor aleatório com  $p = 3$ .

## a) Vetor aleatório

Ex.: Empresa de minério de ferro. Variáveis:  $X_1$ : teor de ferro,  $X_2$ : teor de umidade,  $X_3$ : granulometria.

$\mathbf{X} = [X_1 \ X_2 \ X_3]^T$  é um vetor aleatório com  $p = 3$ .

Ex.: Pesquisa de mercado, amostra de um novo produto para  $n$  pessoas que darão notas de 1 a 7 para cada atributo.

$X_1$ : nota para a cor da embalagem

$X_2$ : nota para o sabor

$X_3$ : nota para preço

$X_4$ : nota para facilidade de compra

## a) Vetor aleatório

Ex.: Empresa de minério de ferro. Variáveis:  $X_1$ : teor de ferro,  $X_2$ : teor de umidade,  $X_3$ : granulometria.

$\mathbf{X} = [X_1 \ X_2 \ X_3]^T$  é um vetor aleatório com  $p = 3$ .

Ex.: Pesquisa de mercado, amostra de um novo produto para  $n$  pessoas que darão notas de 1 a 7 para cada atributo.

$X_1$ : nota para a cor da embalagem

$X_2$ : nota para o sabor

$X_3$ : nota para preço

$X_4$ : nota para facilidade de compra

$\mathbf{X} = [X_1 \ X_2 \ X_3 \ X_4]^T$  é um vetor aleatório com  $p = 4$ .

## b) Vetor de médias



## b) Vetor de médias

- O vetor  $\mu = E(\mathbf{X})$  é chamado vetor de médias do vetor  $\mathbf{X}$ .

$$\mu = E(\mathbf{X}) = \begin{bmatrix} E(X_1) \\ E(X_2) \\ \vdots \\ E(X_p) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix}$$

- $\mu_i = E(\mathbf{X}_i)$  é a esperança da variável  $X_i$
- A média  $\mu_i$  é uma das medidas mais utilizadas para sintetizar a informação de tendência central da distribuição de valores da variável  $X_i$

# c) Matriz de covariâncias

## c) Matriz de covariâncias

- A matriz de covariâncias do vetor aleatório  $\mathbf{X}$  é uma matriz simétrica dada por

$$\Sigma_{p \times p} = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \dots & \sigma_{pp} \end{bmatrix},$$

- em que a diagonal é composta pelas variâncias e os outros elementos são as covariâncias entre as variáveis.

# Variância

- A variância do  $i$ -ésimo componente de  $\mathbf{X}$  é

$$V(X_i) = E[(X_i - \mu_i)^2] = \sigma_i^2 = \sigma_{ii}$$

- O desvio padrão é  $\sigma_i$  ou  $\sqrt{\sigma_{ii}}$
- O desvio padrão informa a dispersão dos valores da v.a.  $X_i$  em relação a  $\mu_i$  (estão próximos ou distantes de  $\mu_i$ )
- Grandes valores de  $\sigma_i$  indicam maior dispersão de valores em relação à média da distribuição

# Covariância

A covariância entre os valores da  $i$ -ésima e  $j$ -ésima variáveis do vetor aleatório  $\mathbf{X}$  é

$$\text{Cov}(X_i, X_j) = E[(X_i - \mu_i)(X_j - \mu_j)] = \sigma_{ij}.$$

# Covariância

- Quando  $i = j$ ,  $Cov(X_i, X_i) = V(X_i)$
- A covariância mede o grau de relacionamento linear entre duas variáveis

# Covariância

- Quando  $i = j$ ,  $Cov(X_i, X_i) = V(X_i)$
- A covariância mede o grau de relacionamento linear entre duas variáveis
- Se valores de  $X_i$  acima da média  $\mu_i$  estiverem associados a valores  $X_j$  acima da média  $\mu_j$ ,  $\sigma_{ij}$  tende a ser positiva (e o mesmo para valores abaixo da média para  $X_i$  e  $X_j$ )
- Se valores de  $X_i$  acima da média  $\mu_i$  estiverem associados a valores  $X_j$  abaixo da média  $\mu_j$ , ou vice-versa,  $\sigma_{ij}$  tende a ser negativa

# Covariância

- Quando  $i = j$ ,  $Cov(X_i, X_i) = V(X_i)$
- A covariância mede o grau de relacionamento linear entre duas variáveis
- Se valores de  $X_i$  acima da média  $\mu_i$  estiverem associados a valores  $X_j$  acima da média  $\mu_j$ ,  $\sigma_{ij}$  tende a ser positiva (e o mesmo para valores abaixo da média para  $X_i$  e  $X_j$ )
- Se valores de  $X_i$  acima da média  $\mu_i$  estiverem associados a valores  $X_j$  abaixo da média  $\mu_j$ , ou vice-versa,  $\sigma_{ij}$  tende a ser negativa
- Covariância tem informação sobre o relacionamento linear entre duas variáveis, mas é difícil julgar se a relação é forte ou não apenas pelo seu valor (correlação é mais útil para isso)



# Covariância

- Em formato matricial

$$\begin{aligned} \text{Cov}(\mathbf{X}) &= E(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^T = \\ &= \begin{bmatrix} E(X_1 - \mu_1)^2 & \dots & E(X_1 - \mu_1)(X_p - \mu_p) \\ E(X_2 - \mu_2)(X_1 - \mu_1) & \dots & E(X_2 - \mu_2)(X_p - \mu_p) \\ \vdots & \vdots & \vdots \\ E(X_p - \mu_p)(X_1 - \mu_1) & \dots & E(X_p - \mu_p)^2 \end{bmatrix} \end{aligned}$$

# Covariância

Forma equivalente da covariância:

$$\text{Cov}(X_i, X_j) = E(X_i X_j) - E(X_i)E(X_j) = E(X_i X_j) - \mu_i \mu_j.$$

# Covariância

Forma equivalente da covariância:

$$\text{Cov}(X_i, X_j) = E(X_i X_j) - E(X_i)E(X_j) = E(X_i X_j) - \mu_i \mu_j.$$

Matricialmente

$$\text{Cov}(\mathbf{X}) = E(\mathbf{X}\mathbf{X}^T) - \boldsymbol{\mu}\boldsymbol{\mu}^T$$

# Covariância

Se  $X_i$  e  $X_j$  são independentes,  $Cov(X_i, X_j) = 0$  (mas o inverso não é verdadeiro):

- $X_i$  e  $X_j$  independentes,  $E(X_i \cdot X_j) = E(X_i)E(X_j)$
- Como  $Cov(X_i, X_j) = E[(X_i - \mu_i)(X_j - \mu_j)]$ ,

$$\begin{aligned} Cov(X_i, X_j) &= E(X_i X_j - X_i \mu_j - X_j \mu_i + \mu_i \mu_j) \\ &= \dots \\ &= E(X_i)E(X_j) - \mu_i \mu_j = 0 \end{aligned}$$

# d) Matriz de correlações

# Correlação

O coeficiente de correlação entre as  $i$ -ésima e  $j$ -ésima variáveis do vetor  $\mathbf{X}$  é definido por

$$\rho_{ij} = \frac{\sigma_{ij}}{\sqrt{\sigma_{ii}\sigma_{jj}}}.$$

- Medida de covariação entre as variáveis em uma escala padronizada

# Correlação

O coeficiente de correlação entre as  $i$ -ésima e  $j$ -ésima variáveis do vetor  $\mathbf{X}$  é definido por

$$\rho_{ij} = \frac{\sigma_{ij}}{\sqrt{\sigma_{ii}\sigma_{jj}}}.$$

- Medida de covariação entre as variáveis em uma escala padronizada
- $-1 \leq \rho_{ij} \leq 1$ ,  $i, j = 1, 2, \dots, p$ . (a covariância possui domínio  $]-\infty, +\infty[$ )
- Na escala padronizada, um valor muito próximo de 1 ou  $-1$  indica que as variáveis estão fortemente associadas
- Quando  $i = j$ ,  $\rho_{ij} = \rho_{ii} = 1$
- Se  $\rho_{ij} = 0$ , as variáveis não possuem associação linear

# Matriz de correlações

A matriz de correlações do vetor aleatório  $\mathbf{X}$  é uma matriz simétrica dada por

$$\rho_{p \times p} = \begin{bmatrix} 1 & \rho_{12} & \dots & \rho_{1p} \\ \rho_{21} & 1 & \dots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \dots & 1 \end{bmatrix}$$

\* Exemplo



# Matriz de correlações

Matricialmente, se tomarmos  $\mathbf{V} = \text{diag}(\boldsymbol{\Sigma}) = \text{diag}(\sigma_{ii})$  e definirmos  $\mathbf{V}^{-1/2} = \text{diag}(1/\sqrt{\sigma_{ii}})$ , teremos

$$\boldsymbol{\rho} = \mathbf{V}^{-1/2} \boldsymbol{\Sigma} \mathbf{V}^{-1/2} = \begin{bmatrix} 1 & \rho_{12} & \dots & \rho_{1p} \\ \rho_{21} & 1 & \dots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \dots & 1 \end{bmatrix}$$

\* Exemplo

## e) Outras variâncias

## e) Outras variâncias

- A matriz de covariâncias  $\Sigma(p \times p)$  de um vetor aleatório  $\mathbf{X}$  possui  $p(p + 1)/2$  parâmetros referentes a
  - $p$  variâncias e
  - $p(p - 1)/2$  covariâncias

## e) Outras variâncias

- A matriz de covariâncias  $\Sigma(p \times p)$  de um vetor aleatório  $\mathbf{X}$  possui  $p(p + 1)/2$  parâmetros referentes a
  - $p$  variâncias e
  - $p(p - 1)/2$  covariâncias
- Se  $p$  for grande, o número de parâmetros pode ser muito grande
- É interessante usar medidas resumo tais como determinante, traço ou o conjunto de autovalores de  $\Sigma$

# Variância total

A variância total do vetor aleatório  $\mathbf{X}$  é definida como

$$\text{Variância total} = \text{traço}(\mathbf{\Sigma}) = \text{tr}(\mathbf{\Sigma}) = \sigma_{11} + \sigma_{22} + \cdots + \sigma_{pp}.$$

# Variância total

A variância total do vetor aleatório  $\mathbf{X}$  é definida como

$$\text{Variância total} = \text{traço}(\mathbf{\Sigma}) = \text{tr}(\mathbf{\Sigma}) = \sigma_{11} + \sigma_{22} + \cdots + \sigma_{pp}.$$

- Forma de sintetizar a variância global da distribuição multivariada por ser a soma das variâncias de todas as variáveis do vetor  $\mathbf{X}$
- Altos valores de variâncias totais indicam maior dispersão global das variáveis  $X_i$ ,  $i = 1, 2, \dots, p$ .

Obs.:  $\text{tr}(\mathbf{\Sigma}) = \text{tr}(\mathbf{\Lambda}) = \lambda_1 + \cdots + \lambda_p$  (soma dos autovalores).

# Variância generalizada

A variância generalizada do vetor aleatório  $\mathbf{X}$  é definida como o determinante da matriz  $\mathbf{\Sigma}$ , ou seja,

$$\text{Variância generalizada} = |\mathbf{\Sigma}|$$

$$\text{Desvio padrão generalizado} = |\mathbf{\Sigma}|^{1/2}$$

- Também fornece uma noção da dispersão global da distribuição multivariada
- Altos valores de variâncias generalizadas também indicam maior dispersão global das variáveis
- Mas, ao contrário da variância total, a variância generalizada é influenciada pelas covariâncias (ou correlações) entre as variâncias (ver Ferreira(2008) para explicação geométrica detalhada)

\* Exemplo

# Variância generalizada

A variância generalizada do vetor aleatório  $\mathbf{X}$  é definida como o determinante da matriz  $\mathbf{\Sigma}$ , ou seja,

$$\text{Variância generalizada} = |\mathbf{\Sigma}|$$

$$\text{Desvio padrão generalizado} = |\mathbf{\Sigma}|^{1/2}$$

- Também fornece uma noção da dispersão global da distribuição multivariada
- Altos valores de variâncias generalizadas também indicam maior dispersão global das variáveis
- Mas, ao contrário da variância total, a variância generalizada é influenciada pelas covariâncias (ou correlações) entre as variâncias (ver Ferreira(2008) para explicação geométrica detalhada)

\* Exemplo



# f) Combinações lineares

# Combinações lineares

- Seja  $\mathbf{X}$  um vetor aleatório, composto por  $p$  variáveis, com vetor de médias  $\boldsymbol{\mu}$  e matriz de covariâncias  $\boldsymbol{\Sigma}$ .
- Seja  $\mathbf{a}_{p \times 1}$  um vetor de escalares (conhecidos), isto é,

$$\mathbf{a} = \begin{bmatrix} a_1 & a_2 & \dots & a_p \end{bmatrix}^T$$

# Combinações lineares

- Seja  $\mathbf{X}$  um vetor aleatório, composto por  $p$  variáveis, com vetor de médias  $\boldsymbol{\mu}$  e matriz de covariâncias  $\boldsymbol{\Sigma}$ .
- Seja  $\mathbf{a}_{p \times 1}$  um vetor de escalares (conhecidos), isto é,

$$\mathbf{a} = \begin{bmatrix} a_1 & a_2 & \dots & a_p \end{bmatrix}^T$$

- Seja  $Z$  a variável definida por

$$Z = \mathbf{a}^T \mathbf{X} = a_1 X_1 + a_2 X_2 + \dots a_p X_p.$$

- Então,  $Z$  é uma v.a. e uma combinação linear das variáveis pertencentes a  $\mathbf{X}$ .

# Combinações lineares

- A média (esperança matemática) de  $Z$  é dada por

$$\mu_Z = E(Z) = a_1\mu_1 + a_2\mu_2 + \cdots + a_p\mu_p,$$

em que  $\mu_i = E(X_i)$ .

- A variância de  $Z$  é dada por

$$\sigma_Z^2 = a^T \Sigma a = \sum_{i=1}^p a_i^2 \sigma_i^2 + \sum_{i \neq j} a_i a_j \sigma_{ij}.$$