

# Análise de componentes principais

Patrícia de Siqueira Ramos

UNIFAL-MG, *campus* Varginha

31 de Outubro de 2018

# ACP via matriz de correlações amostrais

- Os CPs obtidos a partir de  $\mathbf{S}$  são influenciados pelas variáveis de maior variância, sendo pouco úteis quando há grande discrepância entre as variáveis (diferentes escalas)
- Solução: padronizar cada variável pela sua média e desvio padrão, o que equivale a obter CPs a partir da matriz  $\mathbf{R}$

## ACP via matriz de correlações amostrais

- Os CPs são então

$$Y_j = \mathbf{a}_j^T \mathbf{Z} = a_{j1}Z_1 + \cdots + a_{jp}Z_p,$$

em que  $Z_i = \frac{X_i - \bar{X}_i}{\sqrt{S_{ii}}}$  é a variável padronizada e

$$V(Y_j) = \lambda_j, \quad \text{Cov}(Y_i, Y_j) = 0$$

## ACP via matriz de correlações amostrais

- A correlação entre  $Y_j$  e  $Z_i$  é dada por:

$$r_{Y_j, Z_i} = a_{ji} \sqrt{\lambda_j}$$

- e as variáveis  $Z_i$  com maiores coeficientes no CP  $Y_j$  são as mais correlacionadas com o CP

# ACP via matriz de correlações amostrais

- A correlação entre  $Y_j$  e  $Z_i$  é dada por:

$$r_{Y_j, Z_i} = a_{ji} \sqrt{\lambda_j}$$

- e as variáveis  $Z_i$  com maiores coeficientes no CP  $Y_j$  são as mais correlacionadas com o CP
- A variância total de  $\mathbf{Z}$  será

$$\text{Variância total}(\mathbf{Z}) = \sum_{i=1}^p \lambda_i = \text{tr}(\mathbf{R}) = p$$

# Variação explicada

- A proporção da variância total explicada pelo  $j$ -ésimo CP é

$$\frac{V(Y_j)}{\text{V.total de } \mathbf{Z}} = \frac{\lambda_j}{\text{tr}(\mathbf{R})} = \frac{\lambda_j}{p}$$

## Variação explicada

- A proporção da variância total explicada pelo  $j$ -ésimo CP é

$$\frac{V(Y_j)}{\text{V.total de } \mathbf{Z}} = \frac{\lambda_j}{\text{tr}(\mathbf{R})} = \frac{\lambda_j}{p}$$

- Geralmente, quando utilizamos  $\mathbf{R}$  no lugar de  $\mathbf{S}$ , precisamos de um número maior de CPs para explicar a mesma quantidade de variação total obtida utilizando-se  $\mathbf{S}$

## Variação explicada

- A proporção da variância total explicada pelo  $j$ -ésimo CP é

$$\frac{V(Y_j)}{\text{V.total de } \mathbf{Z}} = \frac{\lambda_j}{\text{tr}(\mathbf{R})} = \frac{\lambda_j}{p}$$

- Geralmente, quando utilizamos  $\mathbf{R}$  no lugar de  $\mathbf{S}$ , precisamos de um número maior de CPs para explicar a mesma quantidade de variação total obtida utilizando-se  $\mathbf{S}$

Obs.: Apesar de estarmos usando a mesma notação, os valores de  $a_{ij}$  e  $\lambda_j$  obtidos a partir de  $\mathbf{R}$  não são os mesmos dos obtidos a partir de  $\mathbf{S}$



## Como os CPs predizem $S$

Seja a matriz  $\mathbf{A}$   $p \times p$  formada pelos vetores de coeficientes

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1 & \mathbf{a}_2 & \dots & \mathbf{a}_p \end{bmatrix},$$

que definem os  $p$  CPs.

## Como os CPs predizem $\mathbf{S}$

Seja a matriz  $\mathbf{A}$   $p \times p$  formada pelos vetores de coeficientes

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1 & \mathbf{a}_2 & \dots & \mathbf{a}_p \end{bmatrix},$$

que definem os  $p$  CPs.

A matriz de covariâncias amostrais das variáveis  $X_1, X_2, \dots, X_p$  é dada por (decomposição espectral de  $\mathbf{S}$ )

$$\mathbf{S} = \mathbf{A}\mathbf{\Lambda}\mathbf{A}^T,$$

em que

$$\mathbf{\Lambda} = \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_p \end{bmatrix}.$$

Obs.: Vimos que  $\mathbf{S} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}^T$

# Como os CPs predizem $S$

A matriz de covariâncias amostrais  $S$  pode ser escrita de forma mais simples

$$S = A^* A^{*T},$$

em que  $a_i^* = \sqrt{\lambda_i} a_i$

## Definir número de CPs

- A variação nas  $p$  variáveis originais é totalmente contabilizada por todos os  $p$  componentes principais
- Mas, quantos CPs são necessários para resumir adequadamente um conjunto de dados? Há técnicas variadas:

## Definir número de CPs

- A variação nas  $p$  variáveis originais é totalmente contabilizada por todos os  $p$  componentes principais
- Mas, quantos CPs são necessários para resumir adequadamente um conjunto de dados? Há técnicas variadas:
  - (i) reter os  $k$  primeiros componentes que expliquem grande parte (70 a 80%) da variação total

## Definir número de CPs

- A variação nas  $p$  variáveis originais é totalmente contabilizada por todos os  $p$  componentes principais
- Mas, quantos CPs são necessários para resumir adequadamente um conjunto de dados? Há técnicas variadas:
  - (i) reter os  $k$  primeiros componentes que expliquem grande parte (70 a 80%) da variação total
  - (ii) se a matriz  $\mathbf{R}$  for usada, ficar apenas com os componentes com valores de  $\lambda > 1$  (KAISER, 1958). Outros autores optam por  $\lambda > 0,7$  (JOLLIFE, 1972)

## Definir número de CPs


- A variação nas  $p$  variáveis originais é totalmente contabilizada por todos os  $p$  componentes principais
- Mas, quantos CPs são necessários para resumir adequadamente um conjunto de dados? Há técnicas variadas:
  - (i) reter os  $k$  primeiros componentes que expliquem grande parte (70 a 80%) da variação total
  - (ii) se a matriz  $\mathbf{R}$  for usada, ficar apenas com os componentes com valores de  $\lambda > 1$  (KAISER, 1958). Outros autores optam por  $\lambda > 0,7$  (JOLLIFE, 1972)
  - (iii) analisar um *scree plot* (gráfico de  $\lambda \times$  número de componentes). Devemos procurar pelo “cotovelo”, que é o ponto depois do qual os  $\lambda_i$  diminuem mais lentamente

## Definir número de CPs

- A variação nas  $p$  variáveis originais é totalmente contabilizada por todos os  $p$  componentes principais
- Mas, quantos CPs são necessários para resumir adequadamente um conjunto de dados? Há técnicas variadas:
  - (i) reter os  $k$  primeiros componentes que expliquem grande parte (70 a 80%) da variação total
  - (ii) se a matriz  $\mathbf{R}$  for usada, ficar apenas com os componentes com valores de  $\lambda > 1$  (KAISER, 1958). Outros autores optam por  $\lambda > 0,7$  (JOLLIFE, 1972)
  - (iii) analisar um *scree plot* (gráfico de  $\lambda \times$  número de componentes). Devemos procurar pelo “cotovelo”, que é o ponto depois do qual os  $\lambda_i$  diminuem mais lentamente
  - (iv) verificar se o componente tem interpretação razoável e útil



## Scree plot



## Calcular os escores - a partir da matriz $S$

- Há algumas formas de calcular o escore de um componente em uma observação (a partir da matriz  $S$ ). Uma forma muito comum é:
  - Fazer o produto coeficiente·(valor da variável), somando com os valores de todas as  $p$  variáveis (o valor da variável estará padronizado no caso de se usar a matriz  $R$ )

## Ex.: ACP a partir da matriz $S$

a) Obter os CPs a partir da matriz  $S$  para os dados das 12 empresas lembrando que:

- as variáveis são:  $B$ ,  $L$  e  $P$  (ganhos bruto e líquido e patrimônio)
- $n = 12$  empresas

A decomposição espectral de  $S$  resultou em :

$$\mathbf{\Lambda} = \begin{bmatrix} 41474392 & 0 & 0 \\ 0 & 2539507 & 0 \\ 0 & 0 & 21093 \end{bmatrix},$$

$$\mathbf{P} = \begin{bmatrix} 0,43 & 0,90 & 0,10 \\ 0,03 & 0,10 & -0,99 \\ 0,90 & -0,43 & -0,02 \end{bmatrix}.$$

Ex.: Verificar que  $\mathbf{S} = \mathbf{A}\mathbf{A}^T$

b) Verificar que  $\mathbf{S} = \mathbf{A}\mathbf{A}^T$ . A matriz  $\mathbf{A}$  é a matriz de coeficientes dos CPs (igual à  $\mathbf{P}$ ).

Para conferir:

$$\mathbf{S} = \begin{bmatrix} 9550608,6 & 706121,06 & 14978232,5 \\ 706121,1 & 76269,52 & 933915,1 \\ 14978232,5 & 933915,06 & 34408113,0 \end{bmatrix}.$$

## Ex.: ACP para a matriz $\mathbf{R}$

c) Obter os CPs a partir da matriz  $\mathbf{R}$ , sabendo que a decomposição espectral resultou em

$$\mathbf{\Lambda} = \begin{bmatrix} 2,49 & 0 & 0 \\ 0 & 0,42 & 0 \\ 0 & 0 & 0,08 \end{bmatrix},$$

$$\mathbf{P} = \begin{bmatrix} 0,62 & -0,001 & 0,79 \\ 0,56 & -0,71 & -0,44 \\ 0,56 & 0,71 & -0,43 \end{bmatrix}.$$

Ex.: Verificar que  $\mathbf{R} = \mathbf{A}\mathbf{A}^T$

d) Verificar que  $\mathbf{R} = \mathbf{A}\mathbf{A}^T$ .

Para conferir:

$$\mathbf{R} = \begin{bmatrix} 1 & 0,83 & 0,83 \\ 0,83 & 1 & 0,58 \\ 0,83 & 0,58 & 1 \end{bmatrix}.$$