

Análise de componentes principais

Patrícia de Siqueira Ramos

UNIFAL-MG, *campus* Varginha

1 de Novembro de 2018

ACP via matriz de correlações amostrais

- Os CPs obtidos a partir de **S** são influenciados pelas variáveis de maior variância, sendo pouco úteis quando há grande discrepância entre as variáveis (diferentes escalas)
- Solução: padronizar cada variável pela sua média e desvio padrão, o que equivale a obter CPs a partir da matriz **R**

ACP via matriz de correlações amostrais

- Os CPs são então

$$Y_j = \mathbf{a}_j^T \mathbf{Z} = a_{j1}Z_1 + \cdots + a_{jp}Z_p,$$

em que $Z_i = \frac{X_i - \bar{X}_i}{\sqrt{S_{ii}}}$ é a variável padronizada e

$$V(Y_j) = \lambda_j, \quad \text{Cov}(Y_i, Y_j) = 0$$

ACP via matriz de correlações amostrais

- A correlação entre Y_j e Z_i é dada por:

$$r_{Y_j, Z_i} = a_{ji} \sqrt{\lambda_j}$$

- e as variáveis Z_i com maiores coeficientes no CP Y_j são as mais correlacionadas com o CP

ACP via matriz de correlações amostrais

- A correlação entre Y_j e Z_i é dada por:

$$r_{Y_j, Z_i} = a_{ji} \sqrt{\lambda_j}$$

- e as variáveis Z_i com maiores coeficientes no CP Y_j são as mais correlacionadas com o CP
- A variância total de \mathbf{Z} será

$$\text{Variância total}(\mathbf{Z}) = \sum_{i=1}^p \lambda_i = \text{tr}(\mathbf{R}) = p$$

Variação explicada

- A proporção da variância total explicada pelo j -ésimo CP é

$$\frac{V(Y_j)}{\text{V.total de } \mathbf{Z}} = \frac{\lambda_j}{\text{tr}(\mathbf{R})} = \frac{\lambda_j}{p}$$

Variação explicada

- A proporção da variância total explicada pelo j -ésimo CP é

$$\frac{V(Y_j)}{\text{V.total de } \mathbf{Z}} = \frac{\lambda_j}{\text{tr}(\mathbf{R})} = \frac{\lambda_j}{p}$$

- Geralmente, quando utilizamos \mathbf{R} no lugar de \mathbf{S} , precisamos de um número maior de CPs para explicar a mesma quantidade de variação total obtida utilizando-se \mathbf{S}

Variação explicada

- A proporção da variância total explicada pelo j -ésimo CP é

$$\frac{V(Y_j)}{V.\text{total de } \mathbf{Z}} = \frac{\lambda_j}{tr(\mathbf{R})} = \frac{\lambda_j}{p}$$

- Geralmente, quando utilizamos \mathbf{R} no lugar de \mathbf{S} , precisamos de um número maior de CPs para explicar a mesma quantidade de variação total obtida utilizando-se \mathbf{S}

Obs.: Apesar de estarmos usando a mesma notação, os valores de a_{ij} e λ_j obtidos a partir de \mathbf{R} não são os mesmos dos obtidos a partir de \mathbf{S}

Definir número de CPs

- A variação nas p variáveis originais é totalmente contabilizada por todos os p componentes principais
- Mas, quantos CPs são necessários para resumir adequadamente um conjunto de dados? Há técnicas variadas:

Definir número de CPs

- A variação nas p variáveis originais é totalmente contabilizada por todos os p componentes principais
- Mas, quantos CPs são necessários para resumir adequadamente um conjunto de dados? Há técnicas variadas:
 - (i) reter os k primeiros componentes que expliquem grande parte (70 a 80%) da variação total

Definir número de CPs

- A variação nas p variáveis originais é totalmente contabilizada por todos os p componentes principais
- Mas, quantos CPs são necessários para resumir adequadamente um conjunto de dados? Há técnicas variadas:
 - (i) reter os k primeiros componentes que expliquem grande parte (70 a 80%) da variação total
 - (ii) se a matriz \mathbf{R} for usada, ficar apenas com os componentes com valores de $\lambda > 1$ (KAISER, 1958). Outros autores optam por $\lambda > 0,7$ (JOLLIFE, 1972)


Definir número de CPs

- A variação nas p variáveis originais é totalmente contabilizada por todos os p componentes principais
- Mas, quantos CPs são necessários para resumir adequadamente um conjunto de dados? Há técnicas variadas:
 - (i) reter os k primeiros componentes que expliquem grande parte (70 a 80%) da variação total
 - (ii) se a matriz \mathbf{R} for usada, ficar apenas com os componentes com valores de $\lambda > 1$ (KAISER, 1958). Outros autores optam por $\lambda > 0,7$ (JOLLIFE, 1972)
 - (iii) analisar um *scree plot* (gráfico de $\lambda \times$ número de componentes). Devemos procurar pelo “cotovelo”, que é o ponto depois do qual os λ_i diminuem mais lentamente

Definir número de CPs

- A variação nas p variáveis originais é totalmente contabilizada por todos os p componentes principais
- Mas, quantos CPs são necessários para resumir adequadamente um conjunto de dados? Há técnicas variadas:
 - (i) reter os k primeiros componentes que expliquem grande parte (70 a 80%) da variação total
 - (ii) se a matriz \mathbf{R} for usada, ficar apenas com os componentes com valores de $\lambda > 1$ (KAISER, 1958). Outros autores optam por $\lambda > 0,7$ (JOLLIFE, 1972)
 - (iii) analisar um *scree plot* (gráfico de $\lambda \times$ número de componentes). Devemos procurar pelo “cotovelo”, que é o ponto depois do qual os λ_i diminuem mais lentamente
 - (iv) verificar se o componente tem interpretação razoável e útil

Scree plot



Calcular os escores - a partir da matriz **S**

- Há algumas formas de calcular o escore de um componente em uma observação (a partir da matriz **S**). Uma forma muito comum é:
 - Fazer o produto coeficiente·(valor da variável), somando com os valores de todas as p variáveis (o valor da variável estará padronizado no caso de se usar a matriz **R**)

Ex.: ACP para a matriz **R**

a) Obter os CPs a partir da matriz **R**, sabendo que a decomposição espectral resultou em

$$\mathbf{\Lambda} = \begin{bmatrix} 2,49 & 0 & 0 \\ 0 & 0,42 & 0 \\ 0 & 0 & 0,08 \end{bmatrix},$$

$$\mathbf{P} = \mathbf{A} = \begin{bmatrix} 0,62 & -0,001 & 0,79 \\ 0,56 & -0,71 & -0,44 \\ 0,56 & 0,71 & -0,43 \end{bmatrix}.$$

Ex.: Verificar que $\mathbf{R} = \mathbf{A}\mathbf{A}^T$

b) Verificar que $\mathbf{R} = \mathbf{A}\mathbf{A}^T$.

Para conferir:

$$\mathbf{R} = \begin{bmatrix} 1 & 0,83 & 0,83 \\ 0,83 & 1 & 0,58 \\ 0,83 & 0,58 & 1 \end{bmatrix}.$$